

Этап 1. Исследование данных (EDA)

1.1 Знакомство с данными

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.model_selection import train_test_split
from sklearn.metrics import mean_squared_error, r2_score
```

Загрузка данных из файла 'data.csv' и проверка структуры:

```
data = pd.read_csv('data.csv')
data.info()
```

Статистическое описание данных:

```
data.describe()
```

Проверка на наличие пропусков:

```
data.isnull().sum()
```

Проверка на наличие дубликатов:

```
data.duplicated().sum()
```

Визуализация распределения целевой переменной 'price' (цена):

```
plt.figure(figsize=(10, 5))
sns.histplot(data['price'], bins=50, color='blue', edgecolor='black')
plt.title('Распределение цен')
plt.show()
```

Визуализация взаимосвязей между признаками (матрица корреляции):

```
plt.figure(figsize=(15, 10))
sns.heatmap(data[['area_sqm', 'rooms', 'bathrooms', 'kitchen_sqm', 'living_sqm', 'price']].corr(),
            cmap='coolwarm', annot=True, cbar=True)
plt.show()
```

Визуализация зависимости цены от площади и количества комнат:

```
plt.figure(figsize=(15, 10))
sns.pairplot(data[['area_sqm', 'rooms', 'price']],
            diag_kind='hist',
            kind='scatter',
            color='blue',
            edgecolor='black')
plt.show()
```

1.2 Очистка данных

Удаление строк с пропусками:

```
data = data.dropna()
```

Удаление дубликатов:

```
data = data.drop_duplicates(inplace=True)
```

Преобразование типов данных:

```
data['area_sqm'] = data['area_sqm'].astype(float)
data['rooms'] = data['rooms'].astype(int)
data['bathrooms'] = data['bathrooms'].astype(int)
data['kitchen_sqm'] = data['kitchen_sqm'].astype(float)
data['living_sqm'] = data['living_sqm'].astype(float)
data['price'] = data['price'].astype(float)
```

Нормализация признаков (стандартизация):

```
from sklearn.preprocessing import StandardScaler
scaler = StandardScaler()
data[['area_sqm', 'rooms', 'bathrooms', 'kitchen_sqm', 'living_sqm']] = scaler.fit_transform(data[['area_sqm', 'rooms', 'bathrooms', 'kitchen_sqm', 'living_sqm']])
```

Разделение данных на обучающую и тестовую выборки:

```
train_data, test_data = train_test_split(data, test_size=0.2, random_state=42)
```

1.3 Визуальный анализ

Визуализация распределения целевой переменной 'price' (цена):

```
plt.figure(figsize=(10, 5))
sns.histplot(data['price'], bins=50, color='blue', edgecolor='black')
plt.title('Распределение цен')
plt.show()
```

Визуализация взаимосвязей между признаками (матрица корреляции):

```
plt.figure(figsize=(15, 10))
sns.heatmap(data[['area_sqm', 'rooms', 'bathrooms', 'kitchen_sqm', 'living_sqm', 'price']].corr(),
            cmap='coolwarm', annot=True, cbar=True)
plt.show()
```

Визуализация зависимости цены от площади и количества комнат:

```
plt.figure(figsize=(15, 10))
sns.pairplot(data[['area_sqm', 'rooms', 'price']],
            diag_kind='hist',
            kind='scatter',
            color='blue',
            edgecolor='black')
plt.show()
```

1.4 Визуальный анализ

Визуализация зависимости цены от площади и количества комнат:

```
plt.figure(figsize=(15, 10))
sns.pairplot(data[['area_sqm', 'rooms', 'price']],
            diag_kind='hist',
            kind='scatter',
            color='blue',
            edgecolor='black')
plt.show()
```

Визуализация взаимосвязей между признаками (матрица корреляции):

```
plt.figure(figsize=(15, 10))
sns.heatmap(data[['area_sqm', 'rooms', 'bathrooms', 'kitchen_sqm', 'living_sqm', 'price']].corr(),
            cmap='coolwarm', annot=True, cbar=True)
plt.show()
```

Визуализация зависимости цены от площади и количества комнат:

```
plt.figure(figsize=(15, 10))
sns.pairplot(data[['area_sqm', 'rooms', 'price']],
            diag_kind='hist',
            kind='scatter',
            color='blue',
            edgecolor='black')
plt.show()
```


